MODELE I PROMPTING / LABORATORIUM 03

Ekstrakcja piętra i informacji o windzie

Raport z laboratorium 03 — modele i prompting

Modele: Gemma3:4b · Qwen3:4b · GPT-6 Luna

Autorzy: do uzupełnienia · **Grupa:** do uzupełnienia

Data przygotowania raportu: 22.10.2026. Daty poszczególnych pomiarów nie są zapisywane w CSV.

Najważniejsze wyniki

GPT-6 Luna z czterema przykładami w prompcie uzyskała **100% exact match** przy średnim czasie **1,106 s**. Qwen3:4b osiągnął **100% już w zero-shot**, lecz potrzebował średnio **78,243 s**. Gemma3:4b wymagała wymuszenia JSON Schema, aby odpowiedzi przechodziły walidację; w tym wariancie uzyskała **70% exact match**.

Są to wyniki na **10 różnych notatkach testowych**. Nie stanowią dowodu takiej samej skuteczności na rzeczywistych notatkach kierowców. Raport obejmuje wszystkie dostępne pomiary trzech modeli, ale zakres eksperymentów jest nierówny.

---

1. Cel i zasady zadania

Celem było sprawdzenie, jak model językowy wyodrębnia z polskojęzycznej notatki kierowcy piętro docelowe dostawy oraz informację o obecności windy. Model powinien zwracać obiekt JSON z polami `floor` oraz `elevator`.

Pole	Interpretacja
`floor`	Liczba całkowita, parter = 0; `null`, gdy piętra nie podano lub jest niejednoznaczne
`elevator`	`true`, gdy winda jest; `false`, gdy wyraźnie jej nie ma; `null`, gdy brak informacji

Numer mieszkania i numer domofonu nie są piętrem. Zdanie „Winda nie działa” potwierdza obecność windy, dlatego oczekiwaną etykietą jest `true`. Zadanie dotyczy obecności, a nie sprawności urządzenia.

---

2. Środowisko i dane

Parametr	Wartość
System i powłoka	Windows, PowerShell
Platforma	C#, .NET 10; SDK 10.0.402
Procesor komputera lokalnego	Intel Core Ultra 9 185H
RAM dostępny systemowi	Około 31,4 GiB

Parametr	Wartość
Układ graficzny	Intel Arc Graphics; wykorzystanie akceleracji w pomiarach nie było rejestrowane
Modele lokalne	`gemma3:4b`, `qwen3:4b`, przez Ollamę
Wersja Ollamy podczas pomiarów	Nie została zarejestrowana
Model zdalny	`gpt-6-luna`, OpenAI Chat Completions API
Konfiguracja Luny	`reasoning_effort = none`; temperatura zgodna z danym eksperymentem
Zbiór testowy	`data/examples.csv`: 10 notatek z oczekiwanymi etykietami
Przykłady do promptów	`data/prompt-examples.csv`: 4 osobne notatki
Dodatkowe dane	`notes.csv` i `labeled-notes.csv` nie były używane w zapisanych eksperymentach
Źródło metryk	`results/results.csv` oraz logi w `reports/`

Modele lokalne i model API pracowały w różnych środowiskach. Czas obejmuje wywołanie HTTP i odbiór wyniku; dla Ollamy może obejmować ładowanie modelu, a dla API także opóźnienia sieciowe i obsługę po stronie dostawcy. Nie rejestrowano tokenów ani kosztów, więc nie porównywano kosztu pieniężnego ani czystej szybkości generowania.

Zakres wykonanych pomiarów

Model	EXP-01	EXP-02	EXP-03	EXP-04
Gemma3:4b	wykonano	wykonano	wykonano	wykonano
Qwen3:4b	wykonano	brak wyniku	brak wyniku	brak wyniku
GPT-6 Luna	wykonano	wykonano	wykonano	brak wyniku

W CSV zapisano **18 serii pomiarowych, łącznie 420 wywołań**. Pięć powtórzeń tej samej notatki w EXP-03 nie zwiększa liczby różnych przypadków testowych.

Dla Gemmy istnieją dwa wyniki EXP-01: 5032 ms oraz 4929 ms. W porównaniu głównym użyto ostatniego wyniku 4929 ms, pochodzącego z uruchomienia zapisanego razem z Qwenem. Obie serie pozostawiono w aneksie. Wyniki Luny pochodzą z osobnego uruchomienia.

---

3. EXP-00 — sposób oceny

Metryka	Definicja
Poprawny format	Liczba odpowiedzi zaakceptowanych przez parser: obiekt JSON zawierający oba wymagane pola o właściwych typach
Floor accuracy	Liczba poprawnie rozpoznanych pięter / liczba wszystkich odpowiedzi
Elevator accuracy	Liczba poprawnych etykiet windy / liczba wszystkich odpowiedzi
Exact match	Liczba odpowiedzi z poprawnymi jednocześnie oboma polami / liczba wszystkich odpowiedzi
Średni czas	Łączny czas wywołań modelu / liczba wywołań
Powtarzalne notatki	Notatki, dla których pięć prób dało jeden identyczny zapis wyniku lub błędu parsowania

Odpowiedzi odrzucone przez parser liczą się jako błędne we wszystkich metrykach poprawności. Zatem 0% dla Gemmy bez schematu oznacza niespełnienie kontraktu aplikacji; nie oznacza, że wszystkie wartości wewnątrz odpowiedzi były semantycznie błędne. Etykieta `null` jest pełnoprawnym oczekiwanym wynikiem.

---

4. EXP-01 — porównanie trzech modeli

Ten sam zbiór 10 notatek, prompt bez przykładów, temperatura 0, bez wymuszania JSON Schema.

Model	Poprawny format	Piętro	Winda	Exact match	Czas [s]
Gemma3:4b	0/10	0%	0%	0%	4,929
Qwen3:4b	10/10	100%	100%	100%	78,243
GPT-6 Luna	10/10	100%	90%	90%	1,975

Qwen poprawnie rozpoznał obydwa pola we wszystkich 10 przypadkach i zwrócił odpowiedzi akceptowane przez parser. Luna poprawnie rozpoznała wszystkie piętra, lecz w NOTE-010 podała `elevator = null` zamiast `true`. Gemma zwracała JSON otoczony znacznikami Markdown, co powodowało odrzucanie odpowiedzi.

W tych pomiarach Qwen był około **39,6 razy wolniejszy od Luny** oraz **15,9 razy wolniejszy od Gemmy**. Są to porównania zmierzonych czasów całych wywołań w użytych środowiskach, a nie uniwersalny ranking wydajności modeli.

---

5. EXP-02 — wpływ przykładów w prompcie

Porównano zero-shot, one-shot z pierwszym przykładem („butle są na 1 piętrze") oraz few-shot ze wszystkimi czterema przykładami. Przykłady w prompcie są inne niż notatki testowe. Temperatura wynosiła 0.

Model	Wariant	Poprawny format	Piętro	Winda	Exact match	Czas [s]
Gemma3:4b	zero-shot	0/10	0%	0%	0%	3,923
Gemma3:4b	one-shot	0/10	0%	0%	0%	4,344
Gemma3:4b	few-shot	0/10	0%	0%	0%	5,882
GPT-6 Luna	zero-shot	10/10	100%	90%	90%	1,565
GPT-6 Luna	one-shot	10/10	100%	90%	90%	1,214
GPT-6 Luna	few-shot	10/10	100%	100%	100%	1,106

W Gemmie przykłady nie usunęły problemu formatu, przez co walidacja nadal odrzucała wszystkie odpowiedzi. Nie można na tej podstawie rozstrzygnąć wpływu przykładów na samą trafność wyodrębnionych wartości.

Luna osiągnęła 90% exact match w zero-shot i one-shot, a 100% w few-shot. Różnica dotyczyła NOTE-010: zero-shot zwrócił `null`, one-shot `false`, a few-shot poprawne `true`. Żaden z czterech przykładów nie opisywał bezpośrednio awarii windy, dlatego obserwacja wskazuje na wpływ całego kontekstu przykładów, a nie skopiowanie identycznego przypadku.

W tym uruchomieniu wariant few-shot był także najszybszy. Bez powtarzanych serii i danych o tokenach nie można jednak uznać, że dłuższy prompt z zasady skraca czas odpowiedzi. Dla Qwena EXP-02 nie wykonano.

---

6. EXP-03 — temperatura i powtarzalność

Zastosowano prompt zero-shot, temperatury 0, 0,5 i 1 oraz pięć powtórzeń każdej z 10 notatek. Każdy wiersz obejmuje 50 odpowiedzi.

Model	T	Poprawny format	Piętro	Winda	Exact match	Czas [s]	Powtarzalne notatki
Gemma3:4b	0	0/50	0%	0%	0%	2,585	10/10
Gemma3:4b	0,5	0/50	0%	0%	0%	2,682	10/10
Gemma3:4b	1	0/50	0%	0%	0%	2,772	10/10
GPT-6 Luna	0	50/50	100%	90%	90%	1,305	9/10
GPT-6 Luna	0,5	50/50	100%	92%	92%	1,137	9/10
GPT-6 Luna	1	50/50	100%	92%	92%	1,231	9/10

Gemma uzyskała pozornie idealną powtarzalność 10/10, ponieważ program porównywał komunikaty „Niepoprawny JSON". Nie jest to dowód identyczności surowych odpowiedzi ani poprawnego rozpoznawania danych.

Luna miała 9/10 powtarzalnych notatek przy każdej temperaturze. Zmieniał się wyłącznie wynik NOTE-010. Przy temperaturze 0 wystąpiły cztery odpowiedzi `false` i jedna `null`; przy 0,5 trzy `false`, jedna `null` i jedna `true`; przy 1 trzy `null`, jedna `false` i jedna `true`. Pozostałe dziewięć notatek było poprawnych we wszystkich próbach.

Wzrost exact match z 90% do 92% oznacza tylko jedną dodatkową poprawną odpowiedź na 50 prób. Nie stanowi podstawy do stwierdzenia, że wyższa temperatura poprawia jakość. Temperatura 0 również nie zapewniła pełnej deterministyczności. Dla ekstrakcji danych punktem wyjścia pozostaje niska temperatura, jasna definicja etykiet i walidacja. Dla Qwena EXP-03 nie wykonano.

---

7. EXP-04 — prompt a JSON Schema

Porównano opis formatu wyłącznie w prompcie z natywnym wymuszaniem schematu; temperatura 0.

Model	Wariant	Poprawny format	Piętro	Winda	Exact match	Czas [s]
Gemma3:4b	prompt	0/10	0%	0%	0%	5,002
Gemma3:4b	json-schema	10/10	80%	80%	70%	4,576
GPT-6 Luna	prompt	brak pomiaru	brak pomiaru	brak pomiaru	brak pomiaru	brak pomiaru
GPT-6 Luna	json-schema	brak pomiaru	brak pomiaru	brak pomiaru	brak pomiaru	brak pomiaru

Dla Gemmy schemat zwiększył odsetek odpowiedzi akceptowanych przez parser z 0% do 100%. Nie usunął jednak błędów znaczeniowych: poprawne były 8/10 pięter, 8/10 etykiet windy i 7/10 całych odpowiedzi.

W dostarczonych plikach brakuje wyników EXP-04 Luny oraz wszystkich pomiarów EXP-04 Qwena. Nie przypisano im żadnych wartości ani nie uruchamiano dodatkowych zapytań. Wynik few-shot Luny z EXP-02 nie zastępuje pomiaru JSON Schema.

---

8. Analiza najtrudniejszych przypadków

Notatka	Oczekiwany wynik	Zaobserwowany problem
NOTE-006: „Mieszkanie 15, domofon 15”	`floor = null`, `elevator = null`	Gemma z JSON Schema podała piętro 15: pomyliła numer mieszkania z piętrem
NOTE-009: „Drugie lub trzecie piętro”	`floor = null`, `elevator = null`	Gemma z JSON Schema podała `elevator = false`, mimo braku informacji o windzie
NOTE-010: „Winda nie działa, dostawa na 5p”	`floor = 5`, `elevator = true`	Gemma z JSON Schema podała `floor = null`, `elevator = false`; Luna bez kilku przykładów myliła obecność ze sprawnością windy

W NOTE-010 błędy dotyczą interpretacji domenowej: awaria urządzenia potwierdza jego istnienie. Kolejnym eksperymentem mogłoby być dopisanie tej reguły wprost do promptu i sprawdzenie jej na nowych notatkach, zamiast dalszego dopasowywania rozwiązania wyłącznie do znanych 10 przykładów.

---

9. Rekomendacja i ograniczenia

Na podstawie dostępnych pomiarów najbardziej obiecującym wariantem do dalszych prac jest **GPT-6 Luna, few-shot, temperatura 0**, który osiągnął 10/10 poprawnych odpowiedzi przy średnim czasie 1,106 s. Wariant ten wymaga potwierdzenia na większym, niezależnym zbiorze. Połączenie few-shot z JSON Schema jest propozycją do sprawdzenia, a nie przetestowanym wynikiem tego raportu.

Jeżeli wymagane jest przetwarzanie lokalne, Qwen3:4b jest lepszym punktem wyjścia niż Gemma w badanej konfiguracji: osiągnął 100% exact match bez przykładów, ale z wysokim opóźnieniem. Trzeba jeszcze zbadać rozgrzany model, wpływ konfiguracji wykonania i pozostałe eksperymenty.

Ograniczenia badania:

- Tylko 10 różnych notatek; pojedynczy błąd zmienia wynik serii dziesięciu prób o 10 punktów procentowych.
- Zbiór był wielokrotnie oglądany; brak niezależnego zbioru końcowego i oszacowania niepewności.
- Nierówny zakres badań trzech modeli, w szczególności brak EXP-02–04 Qwena oraz EXP-04 Luny.
- Brak ujednoliconej rozgrzewki, pomiaru tokenów, kosztów, rozrzutu czasów i rejestracji użycia GPU.
- Powtarzalność błędów parsera w Gemmie nie mierzy powtarzalności treści odpowiedzi.
- Wczesne logi Gemmy mają uszkodzone polskie znaki na wyjściu konsoli; w analizie użyto oryginalnych treści z danych i identyfikatorów notatek. Nie ma dowodu, że problem dotyczył wejścia modelu.

10. Odtwarzalność i źródła

Wyniki pochodzą wyłącznie z lokalnych plików; podczas przygotowania raportu nie wykonywano nowych wywołań modeli. Tabele są generowane z CSV, a powtarzalność odczytywana z logów. Do tabel eksperymentów wybierany jest ostatni zapis dla danej konfiguracji.

- `../results/results.csv` — metryki wszystkich zapisanych serii.
- `exp-01-powtorka.txt`, `exp-01-luna.txt` — porównanie modeli.
- `exp-02.txt`, `exp-02-luna.txt` — warianty promptów i odpowiedzi.
- `exp-03.txt`, `exp-03-luna.txt` — powtórzenia oraz stabilność.
- `exp-04.txt` — porównanie formatu Gemmy.
- `../data/examples.csv`, `../data/prompt-examples.csv` — dane i etykiety.
- `../src/ModelLab/Extraction.cs`, `Metrics.cs`, `OllamaClient.cs` oraz `../src/Experiments/` — implementacja.

Plik `generate_report.py` odtwarza Markdown i HTML bez połączeń z API. Po dopisaniu kolejnych pomiarów należy zaktualizować także opisowe wnioski i zakres badania; sam skrypt automatycznie przelicza tabele, ale tekst analizy dokumentuje obecny stan eksperymentów.

Aneks — wszystkie zapisane serie

#	EXP	Model	Wariant	T	N	JSON	Piętro	Winda	Exact	Czas [s]
1	EXP-01	gemma3:4b	zero-shot	0	10	0	0%	0%	0%	5,032
2	EXP-02	gemma3:4b	zero-shot	0	10	0	0%	0%	0%	3,923
3	EXP-02	gemma3:4b	one-shot	0	10	0	0%	0%	0%	4,344
4	EXP-02	gemma3:4b	few-shot	0	10	0	0%	0%	0%	5,882
5	EXP-03	gemma3:4b	x5	0	50	0	0%	0%	0%	2,585
6	EXP-03	gemma3:4b	x5	0.5	50	0	0%	0%	0%	2,682
7	EXP-03	gemma3:4b	x5	1	50	0	0%	0%	0%	2,772
8	EXP-04	gemma3:4b	prompt	0	10	0	0%	0%	0%	5,002
9	EXP-04	gemma3:4b	json-schema	0	10	10	80%	80%	70%	4,576
10	EXP-01	gemma3:4b	zero-shot	0	10	0	0%	0%	0%	4,929
11	EXP-01	qwen3:4b	zero-shot	0	10	10	100%	100%	100%	78,243
12	EXP-01	gpt-6-luna	zero-shot	0	10	10	100%	90%	90%	1,975
13	EXP-02	gpt-6-luna	zero-shot	0	10	10	100%	90%	90%	1,565
14	EXP-02	gpt-6-luna	one-shot	0	10	10	100%	90%	90%	1,214
15	EXP-02	gpt-6-luna	few-shot	0	10	10	100%	100%	100%	1,106
16	EXP-03	gpt-6-luna	x5	0	50	50	100%	90%	90%	1,305

#	EXP	Model	Wariant	T	N	JSON	Piętro	Winda	Exact	Czas [s]
17	EXP-03	gpt-6-luna	x5	0.5	50	50	100%	92%	92%	1,137
18	EXP-03	gpt-6-luna	x5	1	50	50	100%	92%	92%	1,231

Raport wygenerowany z zapisanych pomiarów. Wszystkie czasy dotyczą całych wywołań w badanym środowisku.